Språkmodeller

n-grammodeller

Brukes for sannsynlighetsberegning

Minikorpus:

<s> Lise elsker å danse <\s>

<s> Ola hater å sykle <\s>

<s> Peter liker å danse <\s>

Unigrammer (n=1): <s>, <Lise>, <elsker>, <danse>, <\s> Bigrammer (n=2): <<s>, Lise>, <Lise, elsker>, <elsker, å>, <å, danse>, <danse, <\s> >

$$P(\langle s \rangle Ola hater å danse \langle \langle s \rangle)$$

Minikorpus:

<s> Lise elsker å danse <\s>

<s> Ola hater å sykle <\s>

<s> Peter liker å danse <\s>

$$P(Ola| < s >) * P(hater|Ola) * P(å|hater) * P(danse|å) * P(< \s > |danse)$$

$$=\frac{count(< s >, Ola)}{count(< s >)}*\frac{count(Ola, hater)}{count(Ola)}*\frac{count(hater, \aa)}{count(hater)}*\frac{count(\aa, danse)}{count(\aa)}*\frac{count(danse, < \backslash s >)}{count(danse)}$$

$$= \frac{1}{3} * \frac{1}{1} * \frac{1}{1} * \frac{2}{3} * \frac{2}{2}$$

$$= 0.33 * 1 * 1 * 0.5 * 1 = 0.165$$

= 16.5% sjanse for setningen